



Análisis de Serie Temporal y Pronóstico de Ventas Usando Modelos ARIMA y SARIMA

Universidad Autónoma de Querétaro

Celedón Hernández Andrea Itzel

Temas Selectos de Estadística

Act. Edgar Ruiz

Análisis de Serie Temporal y Pronóstico de Ventas Usando Modelos ARIMA y SARIMA

Introducción

En este análisis, trabajamos con una serie temporal simulada que representa las ventas mensuales de una empresa a lo largo de 36 meses (3 años). El objetivo es realizar un análisis de la serie temporal y ajustar modelos que permitan realizar pronósticos a futuro. Los modelos utilizados en este caso fueron **ARIMA** (Autoregressive Integrated Moving Average) y **SARIMA** (Seasonal ARIMA), con el propósito de identificar la mejor opción para predecir las ventas futuras.

1. Preparación de los Datos

Los datos simulados fueron generados bajo tres componentes principales:

- **Tendencia lineal:** Representando el crecimiento de las ventas a lo largo del tiempo.
- **Estacionalidad:** Un patrón cíclico anual de aumento en ventas en ciertos meses (como en diciembre) y descenso en otros (como en verano).
- **Ruido aleatorio:** Ruido blanco añadido a las ventas para simular la variabilidad natural de los datos.

La serie temporal resultante fue representada gráficamente, mostrando claramente las fluctuaciones estacionales y la tendencia creciente.

python

Copy code

```
# Gráfico de la serie temporal simulada

plt.figure(figsize=(12, 6))

plt.plot(df['Ventas'], label='Ventas Simuladas')

plt.title('Serie Temporal de Ventas Simuladas')

plt.xlabel('Fecha')

plt.ylabel('Ventas')

plt.legend()

plt.show()
```

2. Verificación de la Estacionariedad

Antes de aplicar cualquier modelo de series temporales, es necesario verificar la **estacionariedad** de la serie, es decir, si sus propiedades estadísticas (como la media y la varianza) son constantes en el tiempo. Para ello, utilizamos el **Test de Dickey-Fuller Aumentado (ADF)**.

El resultado del test ADF mostró un valor $p > 0.05$, indicando que la serie no es estacionaria. En este caso, procedimos a **diferenciar la serie** para hacerla estacionaria. Tras la diferenciación, realizamos nuevamente el test ADF, obteniendo un p-valor significativamente bajo, lo que indica que la serie diferenciada es estacionaria.

python

Copy code

```
adf_result = adfuller(df['Ventas'])

# Resultado del test ADF antes y después de la diferenciación
```

3. Determinación de los Parámetros (p, d, q) con ACF y PACF

Para ajustar un modelo ARIMA, es necesario determinar los parámetros ppp, ddd, y qqq de la serie. Utilizamos los gráficos de **Autocorrelación (ACF)** y **Autocorrelación Parcial (PACF)** para identificar el número adecuado de lags en cada componente del modelo.

- **ACF** ayuda a identificar el parámetro qqq (número de términos de la media móvil).
- **PACF** ayuda a identificar el parámetro ppp (número de términos autoregresivos).

python

Copy code

```
plt.figure(figsize=(12, 6))

plt.subplot(121)

plot_acf(df['Ventas_diff'].dropna(), lags=17, ax=plt.gca())

plt.title('ACF de las Ventas Diferenciadas')

plt.subplot(122)

plot_pacf(df['Ventas_diff'].dropna(), lags=17, ax=plt.gca())

plt.title('PACF de las Ventas Diferenciadas')

plt.show()
```

4. Ajuste del Modelo ARIMA(1, 1, 1)

Con base en los resultados de ACF y PACF, ajustamos un modelo **ARIMA(1, 1, 1)**. Este modelo captura una combinación de la autoregresión y la media móvil, y la diferenciación necesaria para hacer la serie estacionaria.

El resumen del modelo ARIMA mostró que el modelo estaba bien ajustado, con buenos valores de los coeficientes. Sin embargo, al analizar los residuos del modelo (es decir, las diferencias entre las predicciones y los valores observados), notamos que los residuos no seguían una distribución normal (lo cual se verificó con el test de Anderson-Darling), lo que sugiere que el modelo podría no estar capturando completamente la dinámica de los datos.

python

Copy code

```
# Residuos del modelo ARIMA

plt.subplot(121)

plt.plot(residuals)

plt.title('Residuos del Modelo ARIMA(1, 1, 1)')
```

5. Pronóstico con ARIMA

El modelo ARIMA fue utilizado para hacer un pronóstico a 12 meses hacia el futuro. El pronóstico generado fue una línea recta, lo que es característico de modelos que no capturan bien la estacionalidad. Este comportamiento reflejó la limitación de ARIMA cuando se trata de series temporales con estacionalidad clara.

python

Copy code

```
# Pronóstico de ARIMA

forecast = results.forecast(steps=12)
```

6. Ajuste del Modelo SARIMA

Dado que los datos muestran un claro patrón estacional, decidimos ajustar un modelo **SARIMA** (Seasonal ARIMA), que incluye términos adicionales para modelar la estacionalidad. En este caso, se utilizó un modelo **SARIMA(1, 1, 1)(1, 1, 1, 12)**, donde $m=12$ representa la estacionalidad anual (12 meses).

El modelo SARIMA mejoró significativamente los resultados, ya que capturó tanto la tendencia como la estacionalidad de las ventas. El pronóstico realizado con el modelo SARIMA mostró una representación mucho más realista de las fluctuaciones futuras de las ventas, con un comportamiento cíclico similar al de los datos históricos.

python

Copy code

```
# Pronóstico con SARIMA
```


```
forecast_sarima = results_sarima.forecast(steps=12)
```


7. Comparación de Resultados y Conclusión

Al comparar los resultados de los pronósticos generados por ambos modelos (ARIMA y SARIMA), se observó lo siguiente:

- **ARIMA:** El modelo produjo un pronóstico plano, sin reflejar las variaciones estacionales, lo cual es un indicativo de que ARIMA no es ideal para datos con estacionalidad clara.
- **SARIMA:** El modelo SARIMA, al incluir términos estacionales, capturó la estacionalidad anual en los datos y produjo un pronóstico mucho más acorde con el comportamiento real de las ventas, mostrando un patrón cíclico.

Conclusión: El modelo SARIMA resultó ser mucho mejor que el modelo ARIMA para este conjunto de datos, ya que logró capturar de manera efectiva tanto la tendencia como la estacionalidad. Este análisis resalta la importancia de considerar la estacionalidad cuando se trabaja con series temporales que presentan ciclos recurrentes, como las ventas mensuales de una empresa.





Resumen del Análisis Comparativo

- El modelo SARIMAX presenta un mejor ajuste global que el modelo ARIMA, ya que tiene un AIC y BIC más bajos, un Log Likelihood más alto y un σ^2 más bajo, lo que indica que captura mejor tanto la tendencia como la estacionalidad de los datos.
- El modelo SARIMAX incorpora componentes estacionales que parecen ser relevantes para este conjunto de datos. Sin embargo, los coeficientes asociados con la estacionalidad no son significativos, lo que sugiere que aunque el modelo captura la estacionalidad, podría haber sobreajuste en los términos estacionales.
- Ambos modelos no presentan problemas de autocorrelación en los residuos, son normales y no muestran heteroskedasticidad significativa, lo que indica que ambos modelos son razonablemente adecuados desde el punto de vista de los residuos.

En conclusión, el modelo SARIMAX es más adecuado para este conjunto de datos que el modelo ARIMA, ya que captura mejor la estacionalidad presente en las ventas. Aunque el modelo SARIMAX tiene ciertos problemas de significancia en los términos estacionales, su capacidad para modelar patrones estacionales y su mejor ajuste general lo hacen superior para realizar pronósticos.